LAPORAN UAS

ANALITIK DAN MANAJEMEN BIG DATA

Dosen:

Nur Hayati, S.Si., M.T.I. .

Dibuat oleh kelompok:

-Fadhil Ali (237006516062)

-Muhammad Alvin Maulana (237006516072)

FAKULTAS TEKNOLOGI KOMUNIKASI DAN INFORMATIKA

PRODI SISTEM INFORMASI

TAHUN 2026

#STEP 1: Data Ingestion & Understanding

1 to 9 of 9 entries Filter

index	dataset	rows	cols	columns	possible_key
0	customers	99441	5	customer_id, customer_unique_id, customer_zip_code_prefix, customer_city, customer_state	customer_id,customer_unique_id
1	geolocation	1000163	5	geolocation_zip_code_prefix, geolocation_lat, geolocation_lng, geolocation_city, geolocation_state	
2	order_items	112650	7	order_id, order_item_id, product_id, seller_id, shipping_limit_date, price, freight_value	order_id,order_item_id,product_id
3	payments	103886	5	order_id, payment_sequential, payment_type, payment_installments, payment_value	order_id
4	reviews	99224	7	review_id, order_id, review_score, review_comment_title, review_comment_message, review_creation_date, review_answer_timestamp	review_id,order_id
5	orders	99441	8	order_id, customer_id, order_status, order_purchase_timestamp, order_approved_at, order_delivered_carrier_date, order_delivered_customer_date, order_estimated_delivery_date	order_id,customer_id
6	products	32951	9	product_id, product_category_name, product_name_lenght, product_description_lenght, product_photos_qty, product_weight_g, product_length_cm, product_height_cm...	product_id
7	sellers	3095	4	seller_id, seller_zip_code_prefix, seller_city, seller_state	seller_id
8	category_translation	71	2	product_category_name, product_category_name_english	

Penjelasan:

Contoh output nyata dari data kamu (baris x kolom)

- customers: **99,441 × 5**
- geolocation: **1,000,163 × 5**
- order_items: **112,650 × 7**
- payments: **103,886 × 5**
- reviews: **99,224 × 7**
- orders: **99,441 × 8**
- products: **32,951 × 9**
- sellers: **3,095 × 4**
- category_translation: **71 × 2**

Total Kolom: 52

Total Rows/Baris: 1.550.992

Kandidat key/join:

- `orders.customer_id` ↔ `customers.customer_id`
- `order_items.order_id` ↔ `orders.order_id`
- `order_items.product_id` ↔ `products.product_id`
- `order_items.seller_id` ↔ `sellers.seller_id`
- `payments.order_id` ↔ `orders.order_id`
- `reviews.order_id` ↔ `orders.order_id`
- `products.product_category_name` ↔ `category_translation.product_category_name`

#STEP 2: Data Quality Assessment

1 to 9 of 9 entries Filter

index	dataset	duplicate_rows	cols_with_nulls	total_nulls	top_null_cols
0	customers	0	0	0	{'customer_id': 0, 'customer_unique_id': 0, 'customer_zip_code_prefix': 0}
1	geolocation	261831	0	0	{'geolocation_zip_code_prefix': 0, 'geolocation_lat': 0, 'geolocation_lng': 0}
2	order_items	0	0	0	{'order_id': 0, 'order_item_id': 0, 'product_id': 0}
3	payments	0	0	0	{'order_id': 0, 'payment_sequential': 0, 'payment_type': 0}
4	reviews	0	2	145903	{'review_comment_title': 87656, 'review_comment_message': 58247, 'review_id': 0}
5	orders	0	3	4908	{'order_delivered_customer_date': 2965, 'order_delivered_carrier_date': 1783, 'order_approved_at': 160}
6	products	0	8	2448	{'product_category_name': 610, 'product_description_lenght': 610, 'product_name_lenght': 610}
7	sellers	0	0	0	{'seller_id': 0, 'seller_zip_code_prefix': 0, 'seller_city': 0}
8	category_translation	0	0	0	{'product_category_name': 0, 'product_category_name_english': 0}

Penjelasan jenis error yang ditemukan:

1) Geolocation duplikat besar

- geolocation punya 261,831 baris duplikat (wajar di dataset Olist karena banyak entri ZIP berulang)

2) Reviews banyak kosong di teks komentar

- `review_comment_title` kosong: 87,656
- `review_comment_message` kosong: 58,247

3) Orders ada tanggal yang missing

- `order_delivered_customer_date` kosong: 2,965
- `order_delivered_carrier_date` kosong: 1,783
- `order_approved_at` kosong: 160

Ini akan ngaruh ke fitur durasi pengiriman (delivery duration).

4) Products ada missing di kategori & atribut

- `product_category_name` kosong: 610
- beberapa kolom produk lain juga kosong (panjang nama, deskripsi, foto, dll.) total null di products: 2,448

#STEP 3: Data Cleaning

1 to 9 of 9 entries Filter

index	dataset	rows_before	rows_after	rows_removed
1	geolocation	1000163	738332	261831
5	orders	99441	96476	2965
6	products	32951	32341	610
0	customers	99441	99441	0
2	order_items	112650	112650	0
4	reviews	99224	99224	0
3	payments	103886	103886	0
7	sellers	3095	3095	0
8	category_translation	71	71	0

Berikut adalah penjelasan dari tabel total baris sebelum vs sesudah dilakukannya tahap cleaning data:

- Dataset geolocation memiliki banyak duplikasi (261,831 baris) dan telah dibersihkan.

- Dataset lain tidak memiliki duplikasi signifikan.

- Missing value pada orders (2.965 baris) dan products (610 baris) telah ditangani dengan cara dibersihkan dari dataset.

Pada tahap data cleaning, dilakukan penghapusan data duplikat serta penghapusan seluruh baris yang memiliki missing value. Metode ini dipilih untuk memastikan bahwa dataset akhir hanya berisi data yang lengkap dan konsisten. Hasil proses cleaning menunjukkan bahwa beberapa dataset mengalami pengurangan jumlah baris yang signifikan, terutama pada dataset reviews, orders, dan products yang memiliki missing value cukup banyak.

#STEP 4: Data Integration

Berikut adalah Tabel hasil dari total rows,final colom,serta unik order yang tersisa untuk dijadikan satu file integrasi data,dengan total :

Total Kolom: 22

Total Baris/Rows: 110.196

...

	final_rows	final_cols	unique_orders	orders_without_items
0	110196	22	96476	0

Berikut adalah Tabel yang sudah menjadi 1 (terintegrasi hanya menjadi satu bagian besar tabel terpusat)

...

	order_id	customer_id	order_status	order_purchase_timestamp	order_delivered_customer_date	order_estimated_delivery_date	customer_unique_id	customer_city
89830	12701d216c208b08132694d01af602a7	39351277fa612e0c7ac8077f7ac038d3	delivered	2018-04-07 23:57:34	2018-04-11 21:06:59	2018-04-25	9613205127b4837f2210caee34d05e41	maua
15725	99ca85d0497f1b958fabcd12b46168e6	f61b744f032d3de6c01387227322b865	delivered	2017-10-15 14:31:50	2017-10-23 17:20:03	2017-11-10	ba9092f02be0cdd12bc6660489fdc700	nazareno
92222	fb415a86a28d4698a9be26d2e871d31c	7087346b1fd0a0ab1ee23d86b692b132	delivered	2017-10-16 21:57:17	2017-11-03 22:03:45	2017-11-17	7422f971f7ad3d66445f8dc98fccc469	salvador
28601	46d941280fb05532830575927a3530f4	a116f93563fbdf7029e5cad149c8e0ee	delivered	2018-01-19 16:33:55	2018-02-14 23:54:59	2018-03-01	be9216b264ae917bff124671d6ca81ed	casa nova
76504	3e22c141d2861860889375c6fd7b89b3	afecd87de20b72ea2bac4b7cdfe977f3	delivered	2018-01-21 12:16:51	2018-02-08 20:26:52	2018-02-26	dfbcc41e559a4afae12abf5adfa17c6a	pacajus
36238	cc2f534a432b33d1e7e67204ab44f662	db969fad91c6771c8617e1a89aa6d810	delivered	2018-07-28 23:32:39	2018-08-14 17:21:27	2018-08-30	da3258a80458be49ca080428f6b88a25	porto seguro
72157	6eafb3047f5d0c7cadeec9d129f0e4d0	40915d2aa40e340e13b8635cf59048d3	delivered	2018-08-26 21:55:14	2018-08-30 01:41:43	2018-09-06	9858c785781f08bd45191d685e5034f3	alvorada
106166	6ae532533e1496cc176aa74fee5aa9bf	1c79e6c28df5dbb32fb4b484b0ae350b	delivered	2017-11-29 21:46:31	2018-01-12 00:58:52	2017-12-26	35dd02aa966dc8f3f5d2277e0cb8fff9	campos dos goytacazes
6329	0d24d62857c1f2d00801a3512dce5d1f	4eba4e54a08ee98d9031561c10c499c5	delivered	2018-07-19 10:49:10	2018-07-26 12:46:54	2018-08-10	e261dace2d1fe8f854e1597b9e507d31	navirai
35290	b282dff26b02dc8eb8715aa5996b13a0	b7afc661f446c22413d9f3e0c1b5aeed	delivered	2018-04-05 07:41:46	2018-04-12 12:42:53	2018-04-19	19f276173a56972adf05f21e789773fe	sao paulo
56856	912343626f370ead5ef2e85a9d757e22	f7622098214b4634b7fe7eee269b5426	delivered	2018-06-01 19:08:41	2018-06-15 00:05:57	2018-07-19	adfa1cab2b2c8706db21bb13c0a1beb1	campo novo do parecis
6664	91fe2d042bdf1fb8d6f2fc33f209ec04	ebcc16a6177788b667355688a7ab5ed6	delivered	2017-06-28 20:19:51	2017-07-28 19:52:01	2017-07-28	8b09aa1a501dd6ce1425b3d610d4e06f	maceio
50598	817856093e04996ba35912467fcb6706	07ad22ca00c8a7fb2137598a670f7de5	delivered	2017-12-06 19:13:41	2017-12-18 20:52:13	2018-01-08	a52452364572cefb3a4eb9ac5b46a33a	caldas novas
68035	4a359800ff0688de3eabc92972987238	7d6a15dac3171fdcfc217ffa8c09ec36	delivered	2018-05-07 10:17:11	2018-05-10 20:20:57	2018-05-23	1c628081cb579ed6035b9aa8614e69f4	ribeirao preto
88596	0dd96ab2fca2927658c83b7e2e954ec9	b2f66716339acf3fd29df8cb5ad63158	delivered	2017-07-09 01:55:26	2017-07-22 13:24:37	2017-08-01	d2185da6e809421 41ffc1dfe5ebbe716	rio de janeiro
82284	b6713a6dc00fb0473d12bd8b08a88cd0	46da9ad64162a07e5830310786802dd1	delivered	2017-10-31 17:54:25	2017-11-13 14:04:53	2017-11-14	4b2f5146918f691e0e1a7204b9cf8248	guaruja
25868	5128a1fb5fd9f44d87fc13d784b3b9b9	3e64eb3cfdeb0c9cb5fb497e7afdd9f6	delivered	2017-10-31 07:53:48	2017-11-20 20:16:59	2017-11-29	1b51af3c9a3ff91fe4c5b90d4aa47154	tocantins
40102	0057199db02d1a5ef41bacbf41f8f63b	c664dc5de5b5f4184bc4ca0285b9f8fe	delivered	2018-01-18 17:05:30	2018-02-06 20:07:20	2018-02-20	9a5b186787a143669398bd8083720c21	sinop
72945	1ce0ea88b5b9dd15c1254739357a8e07	a5469d1164d8137449bb1ca944d6cdbb	delivered	2018-01-29 21:07:31	2018-02-01 19:18:59	2018-02-14	3f173d9ba344efbbb7d148174af2b039	rio claro
54706	4682ccc1cc6188dda05e841ad72bc5e8	afbc6182d564eba59eef474055f2bcdf	delivered	2017-11-28 17:12:53	2017-12-21 19:34:00	2018-01-03	b17fc45501128edb0442e3b966451e1c	tubarao

customer_state	order_item_id	...	price	freight_value	product_category_name_english	seller_city	seller_state	payment_value_sum	payment_types_n	payment_installments_max	review_score_mean	review_count
SP	1	...	59.99	8.88	health_beauty	santo andre	SP	68.87	1.0	2.0	5.0	1.0
MG	1	...	31.90	12.48	computers_accessories	belo horizonte	MG	44.38	1.0	4.0	5.0	1.0
BA	1	...	550.00	135.40	health_beauty	sao paulo	SP	685.40	1.0	8.0	5.0	1.0
BA	1	...	94.90	19.90	sports_leisure	borda da mata	MG	114.80	1.0	1.0	5.0	1.0
CE	1	...	69.90	27.12	bed_bath_table	ibitinga	SP	220.14	1.0	8.0	4.0	1.0
BA	1	...	69.99	27.44	art	salto	SP	97.43	1.0	1.0	3.0	1.0
RS	1	...	199.00	12.88	cool_stuff	montenegro	RS	211.88	1.0	15.0	5.0	1.0
RJ	1	...	79.90	15.31	fashion_underwear_beach	sao paulo	SP	95.21	1.0	9.0	1.0	1.0
MS	2	...	43.00	18.40	sports_leisure	praia grande	SP	122.80	1.0	1.0	5.0	1.0
SP	1	...	110.80	11.40	sports_leisure	sao paulo	SP	122.20	1.0	1.0	5.0	1.0
MT	3	...	529.90	64.69	signaling_and_security	novo hamburgo	RS	3242.84	1.0	10.0	3.0	1.0
AL	1	...	32.99	21.15	fixed_telephony	sao paulo	SP	61.19	1.0	6.0	5.0	1.0
GO	1	...	18.90	34.15	electronics	maringa	PR	53.05	1.0	1.0	1.0	1.0
SP	1	...	46.00	7.87	computers_accessories	ribeirao preto	SP	53.87	1.0	1.0	5.0	1.0
RJ	1	...	39.90	14.10	sports_leisure	sao paulo	SP	54.00	1.0	1.0	5.0	1.0
SP	2	...	35.90	2.96	construction_tools_construction	tatui	SP	155.45	1.0	10.0	5.0	1.0
MG	1	...	89.90	17.88	furniture_decor	ibitinga	SP	107.78	1.0	5.0	1.0	1.0
MT	1	...	20.30	16.79	NaN	limeira	SP	37.09	1.0	1.0	4.0	1.0
SP	1	...	13.99	7.78	perfumery	sao paulo	SP	21.77	1.0	1.0	5.0	1.0
SC	1	...	59.90	16.18	fashion_male_clothing	ibitinga	SP	76.08	1.0	1.0	5.0	1.0

Penjelasan:

Join	Relasi
Orders ↔ Customers	orders.customer_id = customers.customer_id
Orders ↔ Order Items	orders.order_id = order_items.order_id
Order Items ↔ Products	order_items.product_id = products.product_id
Products ↔ Category	products.product_category_name = translation.product_category_name
Order Items ↔ Sellers	order_items.seller_id = sellers.seller_id
Orders ↔ Payments	orders.order_id = payments.order_id
Orders ↔ Reviews	orders.order_id = reviews.order_id

Dataset integrasi dibangun dengan menjadikan tabel orders sebagai pusat relasi. Informasi customer digabung menggunakan customer_id, sedangkan informasi item, produk, dan seller digabung menggunakan order_id dan seller_id. Data payment dan review terlebih dahulu diagregasi per order_id, kemudian digabung ke dataset utama. Hasil integrasi menghasilkan satu tabel terpusat yang mencakup seluruh informasi transaksi dan siap digunakan untuk tahap feature engineering dan analisis.

#STEP 5: Feature Engineering

Berikut adalah gambar tabel (terpusat) dari hasil ditambahnya kolom yang diperintah dalam soal

total_item_value	delivery_duration_days	is_late_delivery	review_sentiment
68.87	3	0	Positive
44.38	8	0	Positive
685.40	18	0	Positive
114.80	26	0	Positive
97.02	18	0	Positive
97.43	16	0	Neutral
211.88	3	0	Positive
95.21	43	1	Negative
61.40	7	0	Positive
122.20	7	0	Positive
594.59	13	0	Neutral
54.14	29	1	Positive
53.05	12	0	Negative
53.87	3	0	Positive
54.00	13	0	Positive
38.86	12	0	Positive
107.78	20	0	Negative
37.09	19	0	Positive
21.77	2	0	Positive
76.08	23	0	Positive

Penjelasan:

Fitur	Rumus	Tujuan
total_item_value	price + freight_value	Nilai total item
delivery_duration_days	delivered − purchase	Lama pengiriman
is_late_delivery	delivered > estimated	Indikator keterlambatan
review_sentiment	score → Positive/Neutral/Negative	Analisis kepuasan

Pada tahap feature engineering, ditambahkan minimal tiga fitur baru untuk memperkaya dataset dan meningkatkan kualitas analisis bisnis. Fitur yang ditambahkan mencakup:

1. Total Order Value untuk merepresentasikan total nilai transaksi,
2. Delivery Duration (hari) untuk mengukur lama pengiriman dari pembelian hingga barang diterima, dan
3. Review Sentiment Flag untuk mengelompokkan review menjadi positif/negatif berdasarkan nilai rating.
   Setiap fitur dibuat dengan rumus atau logika yang jelas dan dijelaskan manfaatnya untuk mendukung analisis (misalnya mengevaluasi performa pengiriman dan hubungannya dengan kepuasan pelanggan

#STEP 6: Validasi Dataset

1 to 7 of 7 entries Filter

index	metric	value
0	Total order unik	96476.0
1	Order dengan item	96476.0
2	Order tanpa item	0.0
3	Total item sales	15419143.41
4	Total payment	15421831.43
5	Mean abs diff	0.0335
6	% abs diff <= 1	99.74

Membuktikan dataset final konsisten:

- jumlah order masuk akal
- total payment vs total item sales tidak jauh beda

Kesimpulan Penjelasan:

Tahap validasi dilakukan untuk memastikan dataset akhir yang sudah terintegrasi dan ditambah fitur benar-benar layak digunakan. Validasi dilakukan dengan cara: (1) mengecek konsistensi jumlah order sebelum dan sesudah integrasi, (2) membandingkan agregasi utama seperti total sales dan total order, serta (3) memastikan relasi data antar tabel tetap valid setelah proses join. Hasil validasi disajikan dalam bentuk tabel, kemudian diambil kesimpulan apakah dataset akhir konsisten dan dapat digunakan untuk analisis bisnis.

#STEP 7: Analisis Data & Insight Bisnis

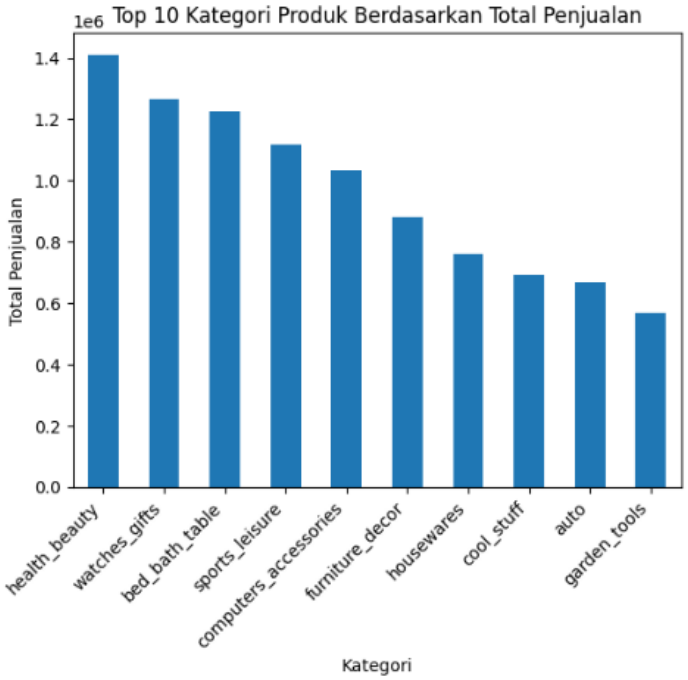

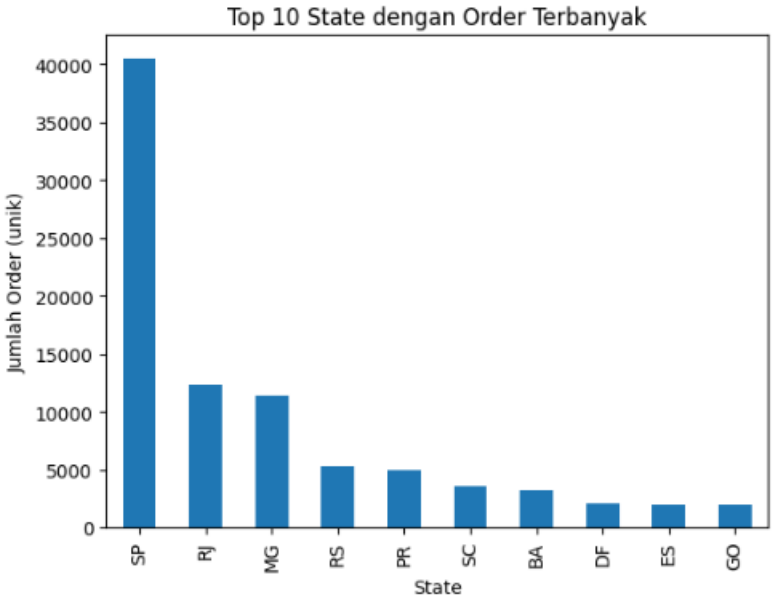

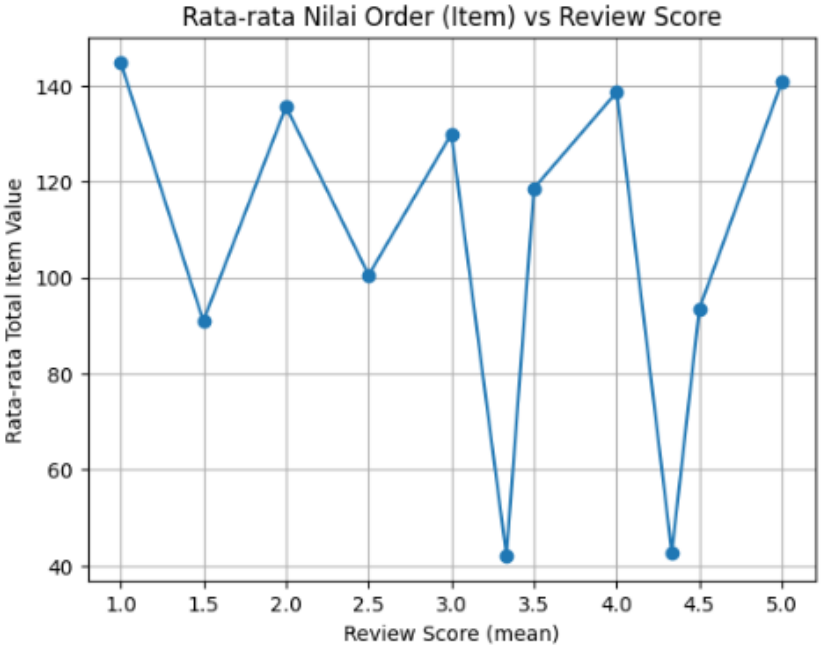

Penjelasan: Pada tahap analisis, dataset akhir digunakan untuk menjawab pertanyaan bisnis sesuai instruksi. Analisis yang dilakukan meliputi: (1) menentukan **kategori produk dengan total penjualan tertinggi**, (2) mengidentifikasi **wilayah dengan jumlah order terbanyak**, dan (3) menganalisis **hubungan antara rating review dan nilai order**. Berdasarkan hasil analisis tersebut, disusun **2 rekomendasi strategis berbasis data** sebagai saran peningkatan performa bisnis unggulan,yaitu:

1. Fokus promosi pada kategori **health_beauty** dan **watches_gifts** karena berkontribusi tertinggi,sehingga 10ogis stok & promosi di kategori ini berpotensi meningkatkan revenue.

2. Optimasi 10ogistic di state **SP, RJ, dan MG** karena volume order terbesar berasal dari wilayah tersebut,sehingga optimasi 10ogistic di wilayah ini akan berdampak besar terhadap kepuasan.

PENUTUP

(PROJECT ANALISIS INI DIBUAT DENGAN GOOGLE COLLABS/PYTHON)

Link lampiran Google Collabs:

https://colab.research.google.com/drive/14eSjpWuXk5wpwoSE95Y3y4JWC6mqAFSf?usp=sharing